

Predicción de Suscripción a Depósitos Bancarios: Un Estudio Empírico

Equipo de Investigación

Abstract

Se presenta un estudio empírico que aborda la predicción de la probabilidad de suscripción de clientes a productos de depósito bancario. Se describen las etapas de obtención y preparación de datos, la selección y optimización de clasificadores basados en gradiente potenciado, las estrategias de balanceo de clases aplicadas, las métricas empleadas para evaluación y las técnicas de explicabilidad utilizadas para interpretar el comportamiento del sistema.

Palabras clave: Clasificación; XGBoost; SMOTE; explicabilidad; AUC ROC

1. Introducción

La predicción de la respuesta de clientes a ofertas financieras constituye un caso de uso frecuente en ciencia de datos aplicada a banca. El presente estudio persigue evaluar un conjunto de decisiones metodológicas —preprocesado, balanceo, modelado y explicabilidad— y documentar un pipeline de referencia reproducible desde la perspectiva metodológica.

2. Materiales y métodos

2.1. Datos

El dataset considerado incluye variables demográficas, socioeconómicas y de interacción con campañas previas; la variable objetivo es binaria y representa la suscripción al producto ofrecido.

2.2. Preprocesado

Se adoptaron las siguientes operaciones de preprocesado:

- tratamiento de valores faltantes por imputación con estrategias simples (media/moda) o por separado por grupo cuando fue necesario;
- codificación de variables categóricas mediante one-hot encoding o codificación ordinal, según la naturaleza de la variable y su cardinalidad;

- normalización o estandarización de variables numéricas en los casos en que algoritmos y transformaciones lo requirieron.

2.3. Balanceo de clases

Se aplicó SMOTE para mitigar el desbalance de clases durante entrenamiento. SMOTE se integró dentro de la etapa de validación cruzada de forma que la generación sintética se realizara exclusivamente en particiones de entrenamiento para evitar fugas de información.

2.4. Modelado

Se entrenaron clasificadores basados en XGBoost (gradient boosting) y variantes en ensamblado. La selección de hiperparámetros se condujo mediante búsqueda bayesiana dirigida a maximizar AUC en validación cruzada estratificada.

2.5. Evaluación

La evaluación tuvo dos niveles: métricas globales (AUC ROC, AUC PR) y métricas de operación (precision@k, recall, F1). Asimismo se evaluó la calibración de probabilidades y la robustez de resultados frente a variaciones de semilla y particionamiento.

2.6. Explicabilidad

Se emplearon métodos de explicabilidad para obtener evidencia interpretable:

- importancia global de variables derivada del estimador;
- explicaciones locales mediante SHAP para cuantificar la contribución de cada variable a predicciones individuales;

3. Resultados

Los experimentos se diseñaron para ofrecer evidencia reproducible sobre la eficacia y robustez del pipeline implementado. A continuación se describen con mayor detalle el protocolo experimental, las métricas informadas, los resultados de interpretabilidad y las pruebas de estabilidad realizadas.

3.1. Protocolo experimental y métricas

Se empleó validación cruzada estratificada (k-fold) y muestreo out-of-time cuando fue posible para estimar desempeño fuera de muestra. El preprocesado, la selección de hiperparámetros y el balanceo con SMOTE se aplicaron exclusivamente sobre las particiones de entrenamiento para evitar fugas. Las métricas reportadas incluyeron AUC ROC, AUC PR, precision, recall (sensibilidad), F1 y Brier score para evaluar calibración. Adicionalmente se analizaron curvas ROC/PR y tablas de confusión en umbrales operativos relevantes.

3.2. Desempeño agregado

Los clasificadores basados en gradiente potenciado mostraron mayor capacidad de discriminación respecto a modelos ligeros de referencia en las particiones evaluadas; en términos agregados la mejora fue estable, con incrementos en AUC ROC moderados pero consistentes. La aplicación de SMOTE mejoró el recall de la clase minoritaria (casos positivos), traducándose en mayor cobertura de clientes potenciales, mientras que la precision experimentó una reducción controlada que entra dentro del trade-off operativo esperado al priorizar detección.

3.3. Calibración y probabilidades

Se comprobó la calibración de probabilidades predichas mediante Brier score y diagramas de calibración; cuando fue necesario se aplicaron calibradores (Platt scaling o isotonic regression) sobre los conjuntos de validación. Tras calibración, las probabilidades resultaron más alineadas con tasas observadas, lo que es crucial para la selección de umbrales en campañas y para estrategias basadas en probabilidad de respuesta.

3.4. Interpretabilidad y extracción de reglas

El análisis de importancia y las explicaciones locales (SHAP) identificaron un subconjunto compacto de features con influencia elevada y consistente a través de particiones.

3.5. Pruebas de robustez

Se realizaron experimentos de sensibilidad ante variaciones de semilla y particionamiento, así como pruebas de subsampling para evaluar estabilidad. Las métricas clave (AUC, recall en umbrales seleccionados) mostraron variaciones moderadas, indicando estabilidad razonable del flujo de entrenamiento. No obstante, se detectaron casos en los que la combinación de features raras y oversampling generaba reglas menos estables, lo que motiva validación adicional en datos out-of-time.

3.6. Implicaciones operativas

Desde la perspectiva operativa, los resultados implican que el modelo puede usarse para priorizar listas de contacto con una mayor densidad de respuestas esperadas. La selección de umbrales debe calibrarse con consideración de coste por contacto y precision, y es recomendable definir reglas de negocio que combinen puntuaciones de modelo con criterios de riesgo o exclusión.

4. Discusión

Los resultados evidencian que los modelos de boosting son adecuados para capturar interacciones no lineales y relaciones complejas en datos tabulares heterogéneos. Sin embargo, la aplicación en entornos productivos debe integrar consideraciones más amplias que abarcan medidas económicas, gobernanza de decisiones y aspectos regulatorios.

4.1. Trade-offs y decisiones de umbral

La mejora en recall asociada al uso de SMOTE y la optimización dirigida a AUC o recall requiere seleccionar umbrales que equilibren costes operativos (p. ej. coste por contacto) y beneficios esperados (conversiones). Es recomendable usar medidas como precision y lift en cohortes relevantes para escoger umbrales y estimar ROI antes de desplegar a escala.

4.2. Validación en producción y A/B testing

La puesta en marcha requiere experimentación controlada (A/B) para medir el impacto real sobre tasas de conversión y costos. Los ensayos en producción permiten cuantificar el efecto neto y validar supuestos de negocio que no siempre reflejan las métricas offline.

4.3. Equidad y auditoría

Es imprescindible evaluar el comportamiento por subgrupos (edad, geografía, segmento socioeconómico) para detectar posibles disparidades. Las reglas y variables con alta influencia deben someterse a auditorías de fairness y a pruebas de sesgo antes de su uso operativo; en caso de detectarse impactos adversos, deben aplicarse medidas de mitigación (reponderación, restricciones o reglas adicionales).

4.4. Gobernanza y controles

Las reglas extraídas y las decisiones automáticas deben incorporarse a un marco de gobernanza que incluya revisión experta, servicio de rollback y registros de decisiones. Asimismo, los pipelines deben contar con monitorización de deriva (covariate shift) y alertas automáticas que disparen reentrenamientos o revisiones manuales cuando cambien las condiciones operativas.

5. Limitaciones

A continuación se detallan las limitaciones más relevantes identificadas en el estudio, con su impacto potencial y recomendaciones de mitigación.

- **Representatividad y sesgo muestral:** los resultados dependen de que las muestras usadas sean representativas del contexto de despliegue. Cambios en la población o en los canales de contacto pueden reducir la validez de las predicciones. *Mitigación:* validar en datos out-of-time y en muestras externas antes de escalado.
- **Efectos del oversampling (SMOTE):** SMOTE genera observaciones sintéticas que pueden amplificar patrones espúrios o crear artefactos en zonas de poca densidad. *Mitigación:* comparar desempeño con y sin oversampling, usar variantes conservadoras de oversampling, y validar reglas generadas en datos reales.

- **Deriva de datos y degradación temporal:** la estabilidad observada offline no sustituye monitorización continua; la deriva covariante o de concepto puede degradar el desempeño rápidamente en producción. *Mitigación:* implementar monitorización de drifts y pipelines de reentrenamiento automatizados con checkpoints y pruebas de regresión.
- **Limitaciones de la evaluación offline:** métricas agregadas como AUC no capturan costos/beneficios reales ni efectos de selección en cohortes comerciales. *Mitigación:* complementar con métricas de negocio (precision@k, coste por contacto, lift y experimentos en producción).
- **Requisitos operativos:** la transición a producción demanda versionado de artefactos, pruebas automáticas de integración y procedimientos de rollback que no siempre están presentes de forma completa. *Mitigación:* establecer procesos de CI/CD para artefactos de modelo y pruebas automáticas que verifiquen compatibilidad de features.

6. Conclusión

Este trabajo documenta un pipeline reproducible que combina preprocesado, balanceo y modelos de boosting con técnicas de explicabilidad orientadas a facilitar la adopción operativa. Los hallazgos principales son:

- Los modelos de boosting muestran buena discriminación en datos tabulares heterogéneos y permiten extraer criterios de priorización valiosos.
- El uso cuidadoso de SMOTE mejora la detección de la clase minoritaria, pero requiere validación externa y controles de sesgo.

Para avanzar hacia una implantación responsable y escalable se recomiendan las siguientes acciones operativas:

1. ejecutar validaciones out-of-time y pruebas en datos independientes para confirmar generalización;
2. realizar experimentos controlados (A/B) en producción para medir impacto comercial real y ajustar umbrales con base en coste-beneficio;
3. implantar monitorización de deriva y pipelines automáticos de reentrenamiento con criterios de parada y rollback;
4. integrar auditorías de equidad y pruebas por subgrupos como requisito previo a la automatización de decisiones;
5. documentar y versionar artefactos de forma sistemática y automatizada para asegurar trazabilidad y revertibilidad.

Con estas medidas, la metodología propuesta puede traducirse en mejoras operativas medibles y sostenibles, manteniendo controles de seguridad, equidad y gobernanza.

Agradecimientos

Se agradece la revisión de los pares y las contribuciones del profesor Pablo Negro, que orientó el desarrollo de este trabajo.

References

- [1] Chen, T., Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
- [2] Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research.
- [3] Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems.